Day26 - ETL pipeline(中)

延續昨天的主題，今天要處理的文件內容比昨天複雜，分別是

PDF：`PagePdfDocumentReader` 、 `ParagraphPdfDocumentReader`

DOCX, PPTX, HTML...：`TikaDocumentReader`

以上都是 apache 的專案，PDF 是 pdfbox，而`TikaDocumentReader`就像它的名稱是 Tike 的專案，Tike 支援的檔案類型可參考官方文件

PDF:

`PagePdfDocumentReader` 與 `ParagraphPdfDocumentReader` 只差在一個是以 Page 為單位，一個是以目錄的章節為單位，顯然以章節為單位拆分內容就不會被截斷，不過不是所有的 pdf 文件都有目錄，我們在程式中可先使用`ParagraphPdfDocumentReader` 失敗時在改用`PagePdfDocumentReader` ，這樣會最大程度優化文件向量化的結果，另外企業將資料向量化時不可能一份一份操作，凱文大叔特地將鐵人賽前幾天的文章轉成 pdf 檔，並存在 resources/pdf 目錄下，來看看程式如何批次處理這麼多份文件

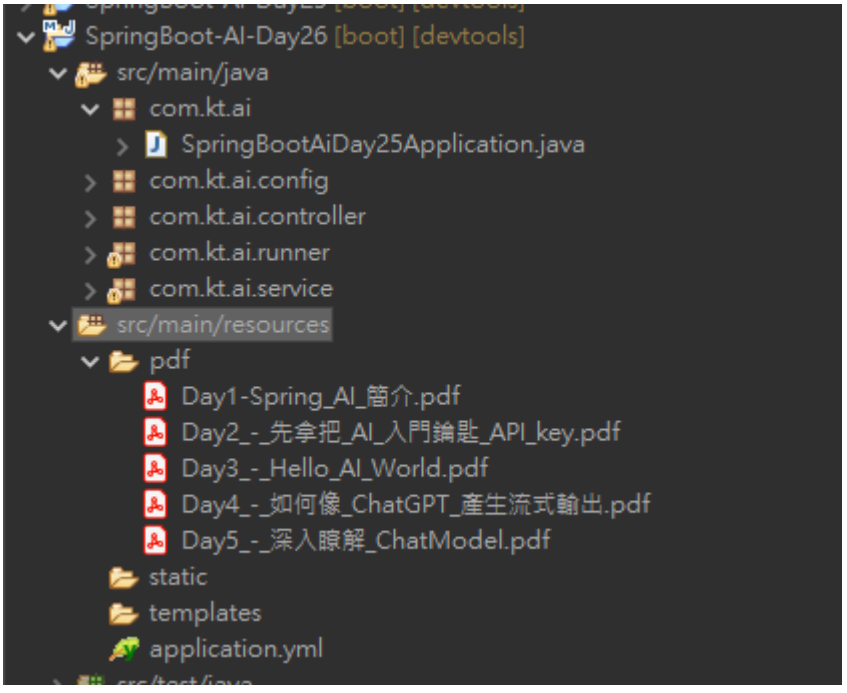

程式實作

首先需要先引入依賴才能使用，編輯 pom.xml 加入下面內容

```
<dependency>
    <groupId>org.springframework.ai</groupId>
    <artifactId>spring-ai-pdf-document-reader</artifactId>
</dependency>
```

EtlService.java : 在 Service 中加入以下函式

```
public List<Document> loadPdfAsDocuments() throws IOException
        ResourcePatternResolver resolver = new PathMatchingRe
    Resource[] resources = new Resource[0];
        resources = resolver.getResources("./pdf/*.pdf");
        //透過上面方式可將指定目錄下所有的pdf檔案載入,後面在針對每份檔
    List<Document> docs = new ArrayList<>();
    for (Resource pdfResource : resources) {
        try {
            //先使用目錄分段讀取方式
            ParagraphPdfDocumentReader pdfReader = new Paragr
            docs.addAll(pdfReader.read());
        } catch (IllegalArgumentException e) {
            //沒有目錄會產生Exception,在改用分頁方式拆分
                PagePdfDocumentReader pdfReader = new PagePdf
                docs.addAll(pdfReader.read());
            }
    }
    return docs;
    }

    public void importPdf() throws IOException {
        //與Text一樣需在使用TokenTextSplitter切塊
        TokenTextSplitter splitter = new TokenTextSplitter();
        vectorStore.write(splitter.split(loadPdfAsDocuments()
    }
```

EtlController.java：Controller 加入對應的 API

```
    @GetMapping("readpdf")
    public List<Document> readPdfFile() throws IOException{
        return etlService.loadPdfAsDocuments();
```

```
    }

    @GetMapping("importpdf")
    public void importPdf() throws IOException{
        etlService.importPdf();
    }
```

程式重點

1. 將整個目錄檔案一次讀取可使用 `PathMatchingResourcePatternResolver`，透過 `getResources("*.pdf")`，就能讀取所有的 pdf 檔
2. 程式先使用 ParagraphPdfDocumentReader 分段拆分，失敗時再改用 PagePdfDocumentReader 分頁拆分
3. 文件類資料都會有內容過長問題，需要再使用 `TokenTextSplitter` 分割成更小塊

成果驗收

直接看最後寫入向量資料庫的成果，可以看到 metadata 預設會保存檔名跟第幾頁，如果使用段落拆分則會顯示哪個段落

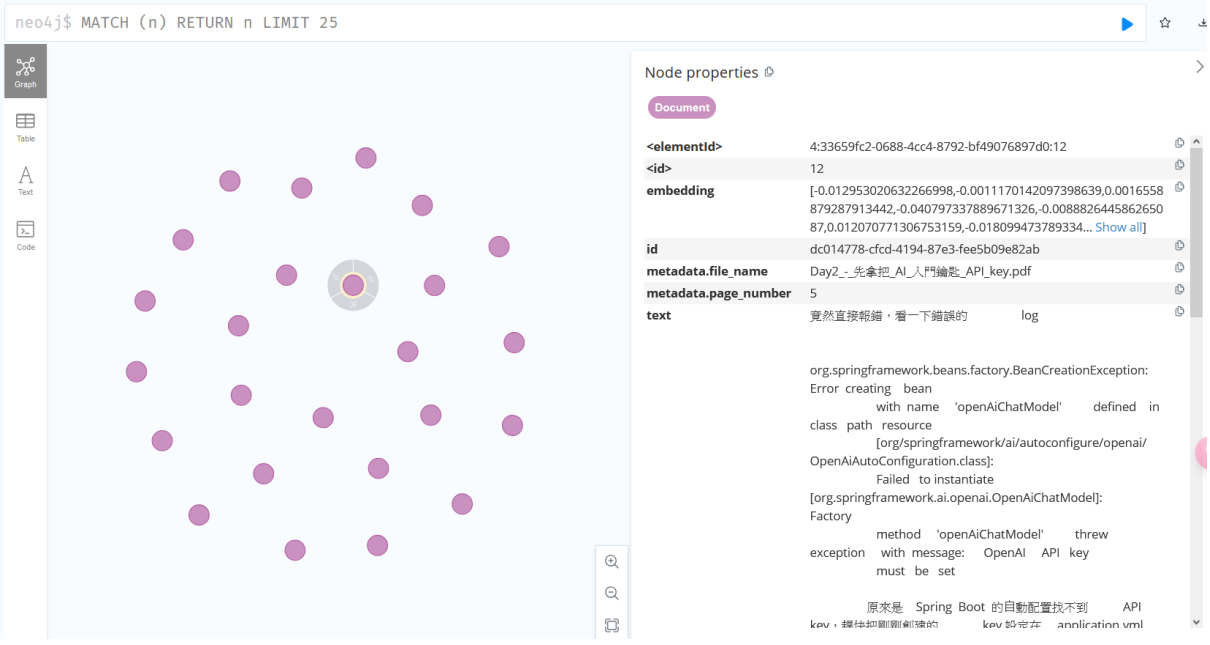

Tike:

Tike 支援的檔案類型非常豐富，有興趣可自行到官網查看，另外 Tike 也有支援 pdf 檔案，不過核心也是使用 pdfbox，使用上個範例能控制更多細節

下面凱文大叔就實作如何讀入 pptx 資料

一樣先把 pptx 集中在一個目錄，這裡我就先放一個檔案

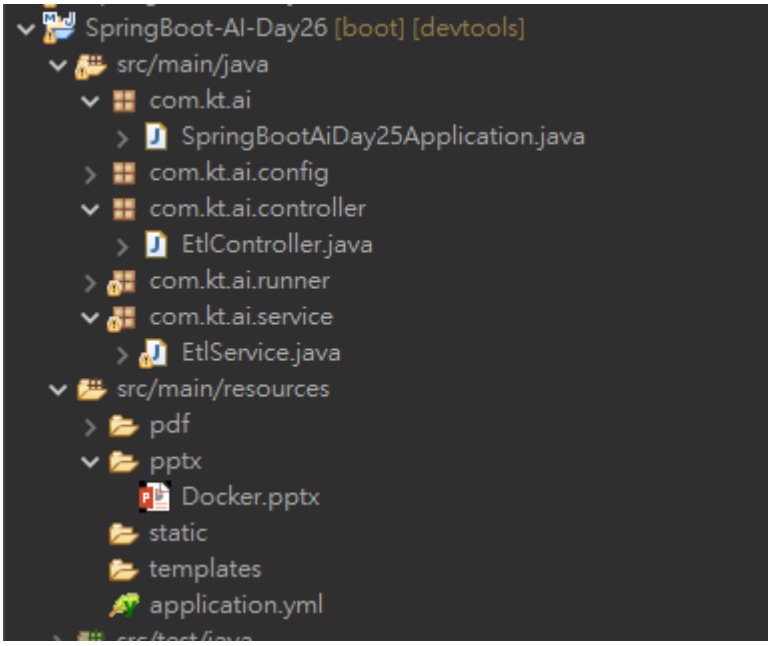

程式實作

pom.xml 一樣需要引入依賴，內容如下

```
<dependency>
    <groupId>org.springframework.ai</groupId>
    <artifactId>spring-ai-tika-document-reader</artifactId>
</dependency>
```

EtlService.java : 在 Service 中加入以下函式

```
public List<Document> loadPptxAsDocuments() throws IOExceptio
    ResourcePatternResolver resolver = new PathMatchingResour
  Resource[] resources = new Resource[0];
    resources = resolver.getResources("./pptx/*.pptx");
  List<Document> docs = new ArrayList<>();
  for (Resource pptxResource : resources) {
        TikaDocumentReader  pptxReader = new TikaDocumentRead
        docs.addAll(pptxReader.read());
  }
```

```
  return docs;
}

public void importPptx() throws IOException {
    TokenTextSplitter splitter = new TokenTextSplitter();
    vectorStore.write(splitter.split(loadPptxAsDocuments()));
}
```

EtlController.java：同樣的 Controller 也加入對應的 API

```
    @GetMapping("readpptx")
    public List<Document> readPptxFile() throws IOException{
        return etlService.loadPptxAsDocuments();
    }

    @GetMapping("importpptx")
    public void importPptx() throws IOException{
        etlService.importPptx();
    }
```

成果驗收

可以看到 metadata 預設一樣會有檔名，若要再添加一些資訊記得在

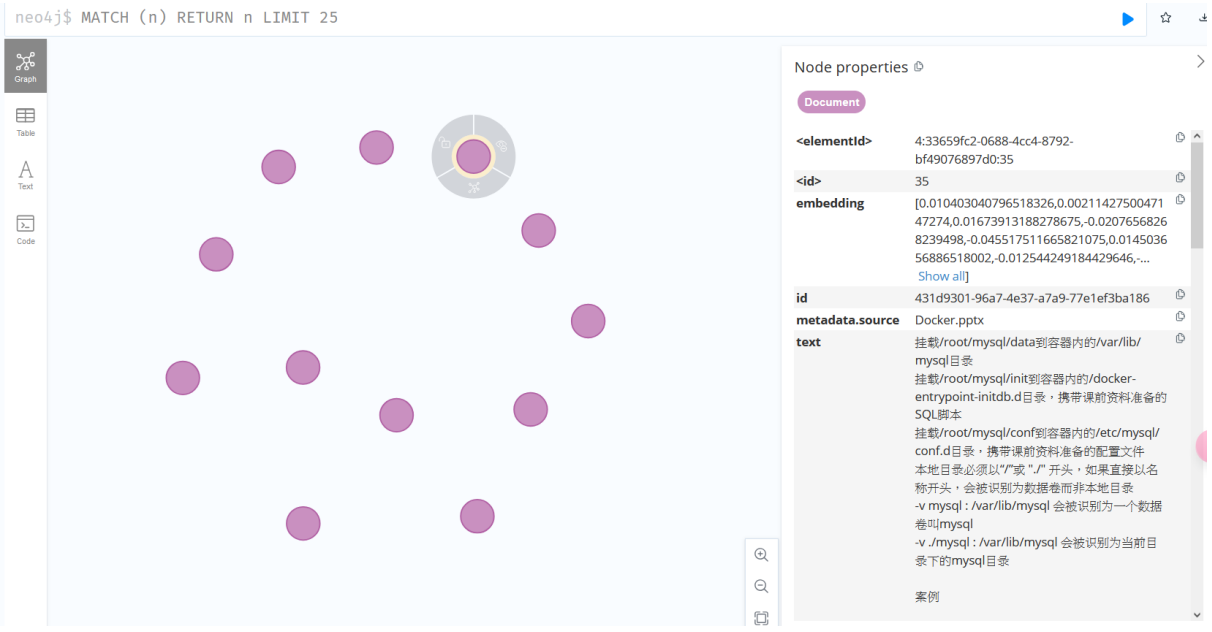

大家應該能發現 Spring 封裝後的工具操作起來都差不多，程式碼的差別就只是 Reader 的類別不一樣，大家可以將 Tike 支援的類別都測試看看